Introdução ao uso do

em Ciências da Saúde

5 - Análise de dados bivariada

Fúlvio Borges Nedel

Departamento de Saúde Pública – SPB
Centro de Ciências da Saúde – CCS
Universidade Federal de Santa Catarina – UFSC

Grups de Recerca d'Amèrica i Àfrica Llatines – GRAAL
http://graal.uab.cat

4 de dezembro de 2017

Roteiro

1 Introdução
- Objetivos da análise

2 Variável dependente é numérica
- Variável independente é numérica
- Variável independente é categórica

3 Variável dependente é categórica

Introdução

GRAAL

- A análise continua com uma descrição do comportamento da variável dependente de acordo com as variáveis independentes
- Crie uma nova linha comentada em seu arquivo de sintaxe. Algo como:

```
### Análise bivariada
...
```

- Inicie com uma sessão vazia, carregue o arquivo de dados e o pacote `epiDisplay`, e "attache" :-) o banco `cursoR2`

```
rm(list=ls())
load('cursoR.RData')
ls()
[1] "cursoR"  "cursoR2"
library(epiDisplay)
attach(cursoR2)
```

Fúlvio Nedel
SPB/UFSC

Objetivos da análise

1. Descrever o Índice de Massa Corporal (IMC) e analisar fatores associados à sua média.
2. Descrever a frequência de categorias do estado nutricional e analisar fatores possivelmente associados à obesidade:
    1. idade
    2. sexo
    3. condição socioeconômica
    4. participação em grupos de promoção da saúde

Temos portanto duas abordagens, uma que toma a variável dependente como numérica e outra que a toma como dicotômica.

Variável dependente é numérica

Fúlvio Nedel
SPB/UFSC

Var. numérica × var. numérica

IMC ∼ idade

Fúlvio Nedel
SPB/UFSC

- correlação
- regressão linear simples (se normal)

```
plot(idade, imc)
# plot(imc ~ idade)
abline(lm(imc ~ idade), col = 2)
abline(v = mean(idade),
       h = mean(imc, na.rm = T),
       col = c(3,4))
```

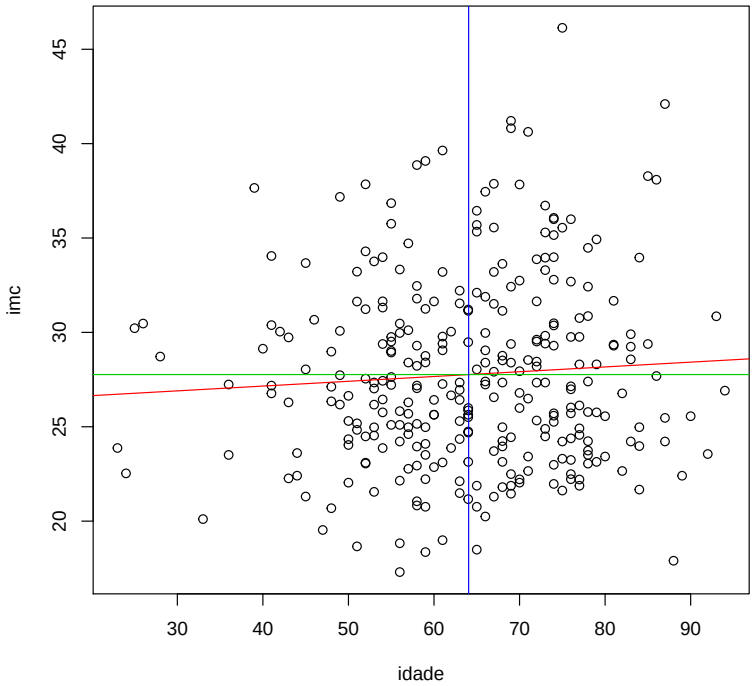


```
?cor.test
?lm
```

```
cor.test(idade, imc, method = 'kendall')
```

```
Kendall's rank correlation tau

data:  idade and imc
z = 0.71744, p-value = 0.4731
alternative hypothesis: true tau is not equal to 0
sample estimates:
       tau
0.02813146
```

```
summary(lm(imc ~ idade))
```

```
Call:
lm(formula = imc ~ idade)

Residuals:
     Min       1Q   Median       3Q      Max
-10.4715  -3.6304  -0.5756   2.8711  18.0931

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 26.14111    1.46285  17.870   <2e-16 ***
idade        0.02536    0.02238   1.133    0.258
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.969 on 297 degrees of freedom
  (1 observation deleted due to missingness)
Multiple R-squared:  0.004304,Adjusted R-squared:  0.000951
F-statistic: 1.284 on 1 and 297 DF,  p-value: 0.2581
```

Var. numérica × var. numérica
IMC ∼ idade

Fúlvio Nedel
SPB/UFSC

Teste de Shapiro-Wilk para normalidade
H_0: a variável tem distribuição normal

```
hist(imc)
```

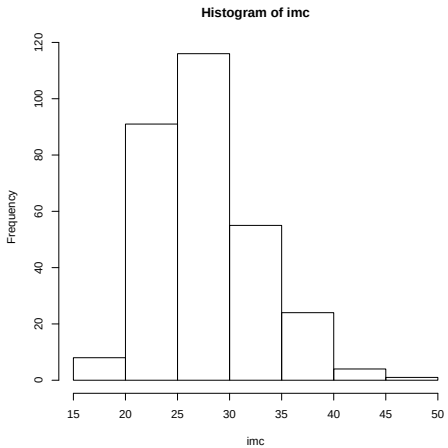


```
hist(idade)
```

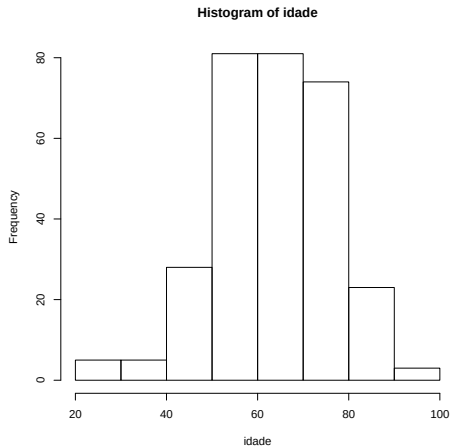


```
shapiro.test(imc)

Shapiro-Wilk normality test

data:  imc
W = 0.97272, p-value = 1.864e-05
# shapiro.qqnorm(imc)
```

```
shapiro.test(idade)

Shapiro-Wilk normality test

data:  idade
W = 0.98656, p-value = 0.00675
# shapiro.qqnorm(idade)
```

Var. numérica × var. categórica dicotômica

IMC ∼ sexo

A função tapply

```
library(e1071)
(media = tapply(imc, sexo, mean, na.rm = T))
Feminino  Masculino
 27.50779  28.26534
(dp = tapply(imc, sexo, sd, na.rm = T))
Feminino  Masculino
 4.650701  5.529724
(assim = tapply(imc, sexo, skewness, na.rm = T))
Feminino  Masculino
0.5069652 0.6976254
(curto = tapply(imc, sexo, kurtosis, na.rm = T))
 Feminino   Masculino
0.06725562 0.06663441
(mediana = tapply(imc, sexo, median, na.rm = T))
Feminino  Masculino
 26.95312  27.44598
(p2575 = cbind(P25 = tapply(imc, sexo,  quantile, probs = .25, na.rm = T),
               P75 = tapply(imc, sexo,  quantile, probs = .75, na.rm = T)))
               P25      P75
Feminino  24.21875 30.36735
Masculino 23.96126 31.54152
(iiq = tapply(imc, sexo, IQR, na.rm = T))
Feminino  Masculino
 6.148597  7.580262
```

Análise por estratos

- A função `tapply` permite a execução de uma função sobre uma variável em grupos separados de outra.
- Veja a família `apply`: `?apply`, `?tapply`, `?sapply`, `?mapply` ...

Var. numérica × var. categórica dicotômica

IMC ∼ sexo

Fúlvio Nedel
SPB/UFSC


```
par(mfrow = c(1,3))
hist(imc[sexo == 'Masculino'], main = 'Homens')
hist(imc[sexo == 'Feminino '], main = 'Mulheres')
plot(imc ~ sexo, ylab = 'imc')
```

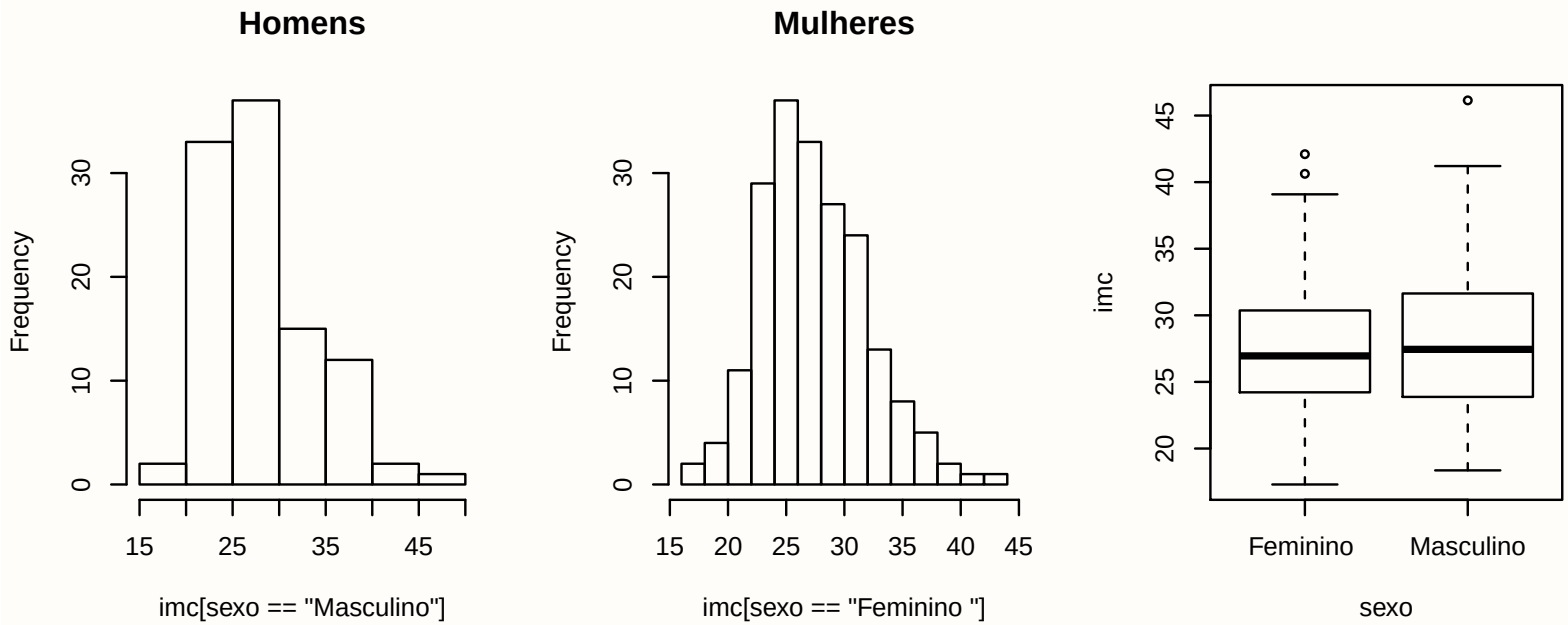


```
tabela = round(cbind(media, dp, assimetria = assim, curtose = curto,
                     mediana, p2575, iiq), 2)
print(xtable::xtable(tabela), size="\\scriptsize",
      format.args = list(decimal.mark = ','))
```

	media	dp	assimetria	curtose	mediana	P25	P75	iiq
Feminino	27,51	4,65	0,51	0,07	26,95	24,22	30,37	6,15
Masculino	28,27	5,53	0,70	0,07	27,45	23,96	31,54	7,58

Var. numérica × var. categórica dicotômica

IMC ∼ sexo

Fúlvio Nedel
SPB/UFSC

- Comparação de médias: testes paramétricos
- Comparação de medianas: testes não paramétricos

```
plot(imc ~ sexo)
```

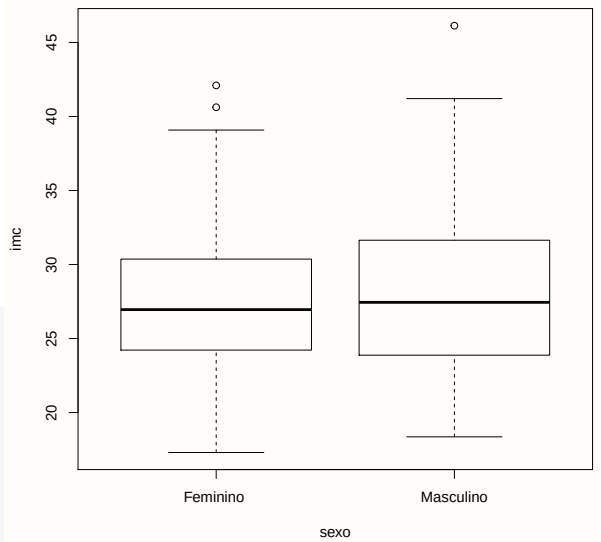


```
t.test(imc ~ sexo)

	Welch Two Sample t-test

data:  imc by sexo
t = -1.1837, df = 176.34, p-value = 0.2381
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -2.0205603  0.5054524
sample estimates:
mean in group Feminino  mean in group Masculino
              27.50779                28.26534
kruskal.test(imc, sexo)

	Kruskal-Wallis rank sum test

data:  imc and sexo
Kruskal-Wallis chi-squared = 0.48678, df = 1, p-value = 0.4854
```

Var. numérica × var. categórica politômica

IMC ∼ condição socioeconômica

ANOVA

```
bartlett.test(imc ~ abep2)

Bartlett test of homogeneity of variances

data:  imc by abep2
Bartlett's K-squared = 1.3948, df = 2, p-value = 0.4979
anova(aov(imc ~ abep2))
Analysis of Variance Table

Response: imc
           Df Sum Sq Mean Sq F value Pr(>F)
abep2       2    0.4  0.1894  0.0074 0.9926
Residuals 278 7089.2 25.5008
pairwise.wilcox.test(imc, abep2)

Pairwise comparisons using Wilcoxon rank sum test

data:  imc and abep2

    A/B C
C   1   -
D/E 1   1

P value adjustment method: holm
?pairwise.t.test
```

```
plot(imc ~ abep2)
```

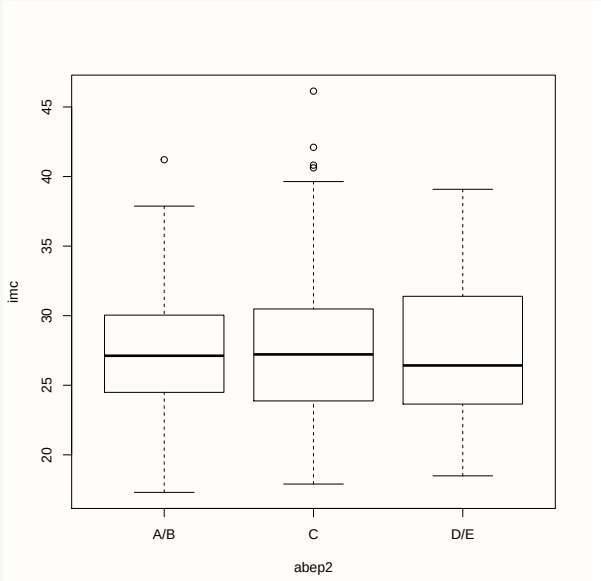

Variável dependente é categórica

Fúlvio Nedel
SPB/UFSC

Var. categórica × var. numérica

Obesidade ∼ idade

Já vimos como descrever a associação entre uma variável numérica e uma categórica

```
round(tapply(idade, obeso, mean, na.rm = T), 2)
```

```
  sim   não
64.02 64.11
```

```
round(tapply(idade, obeso, sd, na.rm = T), 2)
```

```
  sim   não
12.97 12.85
```

```
round(tapply(idade, obeso, median, na.rm = T), 2)
```

```
 sim  não
65.5 64.0
```

```
round(tapply(idade, obeso, IQR, na.rm = T), 2)
```

```
  sim   não
18.25 18.00
```

```
kruskal.test(idade, obeso)
```

```
Kruskal-Wallis rank sum test

data:  idade and obeso
Kruskal-Wallis chi-squared = 0.0104, df = 1, p-value = 0.9188
```

```
plot(obeso, idade,
     ylab = 'idade')
```

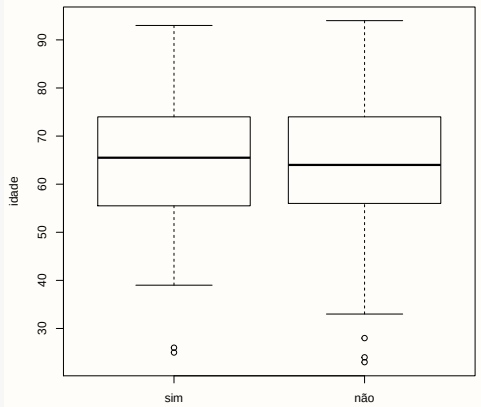

Var. categórica × var. categórica

Obesidade ∼ sexo

```
library(gmodels)
CrossTable(sexo, obeso,
           prop.chisq = F,
           chisq = T, fisher = T)
```

```
   Cell Contents
|-------------------------|
|                       N |
|           N / Row Total |
|           N / Col Total |
|         N / Table Total |
|-------------------------|


Total Observations in Table:  299
```

	obeso		
sexo	sim	não	Row Total
Feminino	54	143	197
	0.274	0.726	0.659
	0.643	0.665	
	0.181	0.478	
Masculino	30	72	102
	0.294	0.706	0.341
	0.357	0.335	
	0.100	0.241	
Column Total	84	215	299
	0.281	0.719	

Var. categórica × var. categórica

Obesidade ∼ sexo

```
library(gmodels)
CrossTable(sexo, obeso,
           prop.chisq = F,
           chisq = T, fisher = T)
```

```
   Cell Contents
|-------------------------|
|                       N |
|           N / Row Total |
|           N / Col Total |
|         N / Table Total |
|-------------------------|
```

sexo	obeso: sim	obeso: não	Row Total
Feminino	54	143	197
	0.274	0.726	0.659
	0.643	0.665	
	0.181	0.478	
Masculino	30	72	102
	0.294	0.706	0.341
	0.357	0.335	
	0.100	0.241	
Column Total	84	215	299
	0.281	0.719	

```
Total Observations in Table:  299

Statistics for All Table Factors

Pearson's Chi-squared test
------------------------------------------------------------
Chi^2 =  0.1331494     d.f. =  1     p =  0.7151887

Pearson's Chi-squared test with Yates' continuity correction
------------------------------------------------------------
Chi^2 =  0.05253029     d.f. =  1     p =  0.8187175
```

Var. categórica × var. categórica

Obesidade ∼ sexo

```
library(gmodels)
CrossTable(sexo, obeso,
           prop.chisq = F,
           chisq = T, fisher = T)
```

```
   Cell Contents
|-------------------------|
|                       N |
|           N / Row Total |
|           N / Col Total |
|         N / Table Total |
|-------------------------|
```

	obeso		
sexo	sim	não	Row Total
Feminino	54	143	197
	0.274	0.726	0.659
	0.643	0.665	
	0.181	0.478	
Masculino	30	72	102
	0.294	0.706	0.341
	0.357	0.335	
	0.100	0.241	
Column Total	84	215	299
	0.281	0.719	

```
Total Observations in Table:  299

Statistics for All Table Factors

Fisher's Exact Test for Count Data
-----------------------------------------------------------
Sample estimate odds ratio:  0.9065962

Alternative hypothesis: true odds ratio is not equal to 1
p =  0.786248
95% confidence interval:  0.5186835 1.601355

Alternative hypothesis: true odds ratio is less than 1
p =  0.407084
95% confidence interval:  0 1.467891

Alternative hypothesis: true odds ratio is greater than 1
p =  0.6932558
95% confidence interval:  0.5637979 Inf
```

Var. categórica × var. categórica

Obesidade ∼ sexo

Fúlvio Nedel
SPB/UFSC


```
tabpct(sexo, obeso)
```

```
Original table
           obeso
sexo         sim  não  Total
  Feminino    54  143    197
  Masculino   30   72    102
  Total       84  215    299

Row percent
           obeso
sexo            sim     não  Total
  Feminino       54     143    197
               (27.4)  (72.6)  (100)
  Masculino      30      72    102
               (29.4)  (70.6)  (100)

Column percent
           obeso
sexo         sim       %  não       %
  Feminino    54  (64.3)  143  (66.5)
  Masculino   30  (35.7)   72  (33.5)
  Total       84   (100)  215   (100)
```

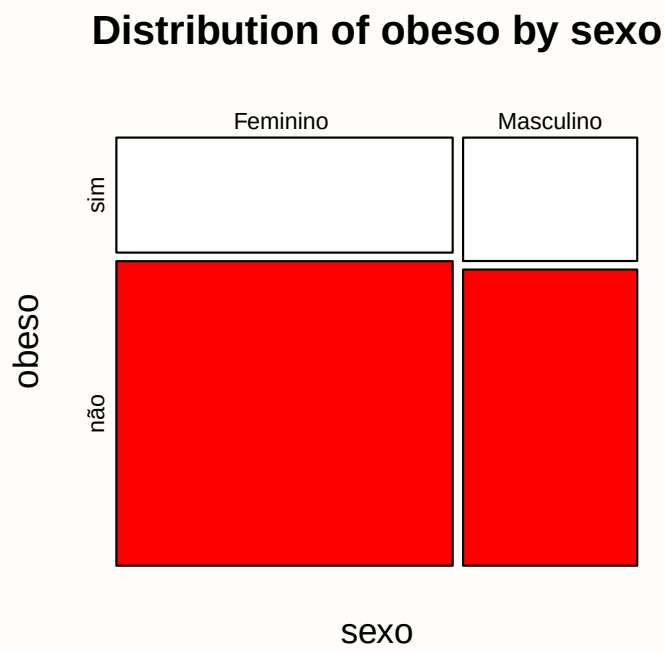

$$RP_{m/f} = \frac{29,4}{27,4} = 1,073$$

$$OR_{m/f} = \frac{29,4/70,6}{27,4/72,6} = \frac{0,416}{0,377} = 1,103$$

```
?chisq.test(sexo, obeso)
?fisher.test(sexo, obeso)
```

Var. categórica × var. categórica

Obesidade ∼ sexo


```
Epi::twoby2(sexo, obeso)
2 by 2 table analysis:
------------------------------------------------------
Outcome    : sim
Comparing : Feminino  vs. Masculino

          sim não    P(sim) 95% conf. interval
Feminino   54 143    0.2741    0.2164   0.3406
Masculino  30  72    0.2941    0.2139   0.3895

                                    95% conf. interval
            Relative Risk:  0.9320    0.6393   1.3586
        Sample Odds Ratio:  0.9063    0.5342   1.5376
Conditional MLE Odds Ratio:  0.9066    0.5187   1.6014
    Probability difference: -0.0200   -0.1307   0.0835

             Exact P-value: 0.7862
         Asymptotic P-value: 0.7152
------------------------------------------------------
```

Var. categórica × var. categórica

Obesidade ∼ sexo

```
epiR::epi.2by2(table(sexo,obeso))
             Outcome +    Outcome -       Total         Inc risk *
Exposed +           54          143         197               27.4
Exposed -           30           72         102               29.4
Total               84          215         299               28.1
                  Odds
Exposed +        0.378
Exposed -        0.417
Total            0.391

Point estimates and 95 % CIs:
-------------------------------------------------------
Inc risk ratio (W)                          0.93 (0.64, 1.36)
Odds ratio (W)                              0.91 (0.53, 1.54)
Attrib risk (W) *                           -2.00 (-12.82, 8.82)
Attrib risk in population (W) *             -1.32 (-11.52, 8.89)
Attrib fraction in exposed (%)              -7.30 (-56.41, 26.39)
Attrib fraction in population (%)           -4.69 (-33.40, 17.84)
-------------------------------------------------------
 X2 test statistic: 0.133 p-value: 0.715
 W: Wald confidence limits
 * Cases per 100 population units
```

Var. categórica × var. categórica

Obesidade ∼ sexo

```
Rcoisas::bolero(sexo, obeso)
============================================================
                    Tabela 2 por 2
          bolero(independente, dependente, dec=2, dnn)
------------------------------------------------------------
Var. dependente : obeso = sim
Var. independente: sexo = Feminin

           obeso
sexo         sim não Sum
  Feminino    54 143 197
  Masculino   30  72 102
  Sum         84 215 299

Proporções (%)
           obeso
sexo         sim  não
  Feminino  27.4 72.6
  Masculino 29.4 70.6

  Razão de Probabilidades: 0.93 ; IC95% (assintótico): 0.64 1.36
                                   IC95% (exato)      : 0.60 1.36
  Razão de Odds          : 0.91 ; IC95% (exato)      : 0.52 1.60
  Valor-p: Pearson, Yates: 0.819 ; Fisher: 0.786
============================================================
```

```
barplot(table(sexo,obeso), beside = T,
        xlab = 'Obesidade',
        legend.text = levels(sexo),
        args.legend = list(x="topleft"))
```

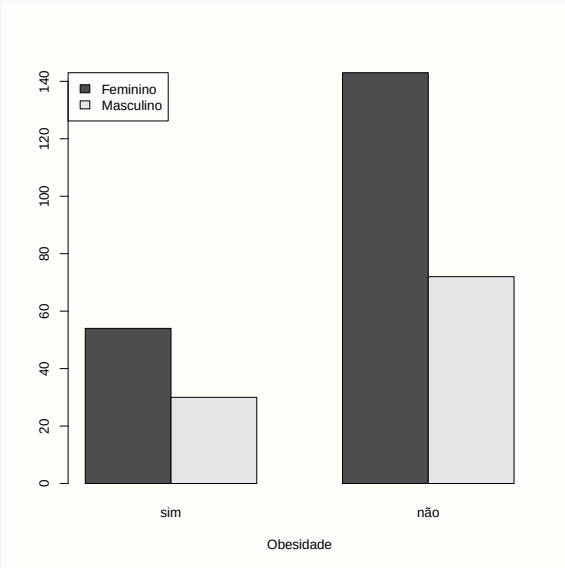

Descrição bivariada

- Descreva a relação entre o peso e a altura (estão no banco `cursoR`)
- Descreva a relação entre o IMC e a participação em grupos
- Descreva a relação entre o IMC e a condição socioeconômica em sete níveis (variável `abepcls`, em `cursoR`)
- Descreva a relação entre a obesidade e a participação em grupos de promoção à saúde
- Descreva a relação entre a obesidade e a condição socioeconômica